

林晓斌

☎ 19124873136 · ✉ linxiaobin_dev@163.com · 10 年工作经验

📍 东莞理工 · 本科 · 电子信息工程 · 2012-2016

AI 基础设施架构师 | 大模型应用工程化落地 | 语音 AI 架构 | Agent 编排与模型微调

个人优势

- 8 年千万级 App 与业务系统底蕴**，熟练掌握 React / Vue3 及复杂状态管理；精通 ReadableStream 流式渲染、Websocket 实时通信及大屏 / 复杂业务系统的大型 Mock 体系设计。
- Node.js (NestJS / Express) 与 Python (FastAPI / asyncio) 双栈高并发开发**，熟练处理异步并发调度、指数退避重试及内存泄漏分析，具备高性能 API 架构设计与微服务降级 / 限流能力。
- LangGraph / LangChain 复杂 Agent 智能体工作流**，精通多智能体状态机设计、Checkpointner 状态持久化及基于 SSE (Server-Sent Events) 的大模型流式网关协议。
- 检索增强生成 (RAG) 全链路精通**，擅长复杂文档语义切片；具备大物流 / 供应链垂直领域知识库落地经验，精通 HNSW 稠密向量与 BM25 稀疏混合检索、Cross-Encoder Rerank 重排及 pgvector / Milvus 向量数据库性能调优。
- 提示词全生命周期管理**，熟练运用 Pydantic Schema / JSON Mode 确保 LLM 稳定输出复杂结构化指令；建立基于 LLM-as-a-Judge 与自动化评测的数据飞轮及负样本优化体系。
- LLaMA-Factory 业务微调全流程 (SFT / QLoRA / LoRA)**，深入理解 Prefix Caching / KV Cache 显存机制，具备首字生成延迟 (TTFT) 优化与生产级多模型动态路由落地经验。
- 实时语音交互 (RTC) 链路掌握**，熟练集成 ASR / TTS 与声音复刻技术；针对物流终端 / PDA 及骑手配送弱网环境，具备 FEC 前向纠错及自适应 Jitter Buffer 底层优化经验，保障极端场景下的语音可用性。
- Docker / Linux / Git 高效工作流掌控**，具备 structlog 结构化日志、Request-ID 全链路追踪基建搭建能力。拥有敏锐的业务嗅觉，能独立主导并带领团队完成 AI 业务线从 0 到 1 的高质量交付。

工作经历

跨越新科技

AI 应用开发架构师 · 2024.05-至今

- 全面负责集团 AI 中台架构设计与技术选型，主导构建基于 MCP 协议的多 Agent 联邦共享服务集群，并将其转化为集团级研发效能底座。
- 技术领域涵盖 RAG 检索优化、LLM 推理压缩、LangGraph Agentic Workflow、SFT/DPO 模型微调及全链路工程化治理。
- 成功推动 AI 在智能客服、供应链合规、单证审计等核心业务的规模化落地，实现客服转化率显著增长；通过自研 SWE-Agent 工厂将研发迭代周期缩短 50% 以上。

跨越速运集团

高级 iOS 开发工程师 / 移动端架构师 · 2019.07 ~ 2024.05

- 负责集团核心物流 App 及调度端系统的移动架构设计与性能攻坚，支撑日均千万级订单的处理负载。
- 主导移动端架构从 MVC 向 MVVM + 跨平台协同的平滑演进，通过组件化架构拆解业务边界，提升核心模块的解耦度与工程复用率。
- 针对物流场景高频网络波动与复杂地理位置轨迹上报，设计自适应网络容灾策略与高性能点位压缩算法，移动端轨迹丢失率降低 30% 以上。
- 支撑集团从传统配送向智能化调度的数字化转型，负责复杂调度大屏的移动端渲染优化，保障双十一期间极高并发下的系统稳定性。

网易

iOS 开发工程师 · 2016.09 ~ 2019.06

- 参与网易核心客户端产品的开发与迭代，负责移动端业务模块的设计与交付。
- 深入研读网易内部高性能渲染框架，优化复杂 UI 交互下的列表滑动帧率，确保核心功能在多种机型下的平滑体验。
- 严格执行大厂代码质量规范与自动化单元测试体系，参与并推动多项移动端工程化改进方案，保障产品版本的稳定迭代。

项目

集团AI智能客服与大模型基础设施

AI 技术负责人 · 2024.12 ~ 至今

日均千万级订单物流集团，客服话务超百万通/日，人工坐席成本占客服中心 OPEX 60%+。主导端到端 AI 客服底座建设，分三阶段完成 RTC 语音系统上线、私有化模型认知对齐、MCP 协议基座重构，AI 独立解决率与熟练人工坐席持平（18.2% vs 19.7%）。

第一阶段：全场景实时语音客服与调度引擎（流式 Agent / RTC 架构）（2024.12 ~ 2025.03）

- 从零架构端云协同流式语音 AI 底座，覆盖语音接单、催单查询、运费计算、理赔协商等 12 个高频话务意图。基于 Prompt Pilot 搭建话术管理体系，构建物流语料评测集实现自动化评分与版本对比，对错误计费、越权承诺等负样本进行提示词重构。
- 针对《航空禁运名录》与理赔 SOP 等复杂条款，采用自定义标识符语义切片解决传统截断问题；应用 HNSW_HYBRID 混合检索 + Int8 量化，构建航线/战区/货物类型多维 Metadata 过滤，存储降低 75%。引入 base-rerank 轻量模型动态平衡 dense_weight，物流专有名词命中率显著提升，检索速度提升 4 倍。
- 通过固定 RAG 检索片段排序、合并 System Prompt 等手段深度触发 Prefix Caching 与 KV Cache，复杂场景 TTFT 从 15s → 2s 内。针对不同业务进行模型选型与资源池优先级调优。
- 基于 ASR 实时捕获客户情感波动，配合 TTS 声音复刻实现情绪化安抚。利用 FEC 前向纠错 + 自适应 Jitter Buffer，在 50% 高丢包环境下实现语音对话无感知恢复。建立 Max Token 分级控制模型，基于 95% 话务覆盖率边界动态配置推理与输出比例。
- 部署 Prometheus + Grafana 实时看板拆分 Token 消耗，识别递归查询导致的 Token 雪崩等异常模式；设置单请求成本上限与 QPS-Token 联合熔断阈值，月均 API 成本波动 ±8% 以内。

第二阶段：集团专属大模型私有化基座与数据闭环（SFT / DPO 定制工程）（2025.03 ~ 2025.06）

- 设计全流程清洗管线，过滤图片/语音/表情包等非文本消息。基于时间窗口（30min）+ Embedding 余弦相似度双重策略完成多轮对话切分，采用正则 + NER 两层脱敏处理敏感信息，脱敏准确率 98%。
- 本地使用 LLaMA-Factory + Qwen2.5-3B-Instruct 进行 QLoRA 微调（rank=64, alpha=128, lr=2e-4），单卡 RTX 4090 约 40 分钟/轮验证方向；验证通过后上传火山引擎方舟对豆包大模型 1.5 生产级 LoRA 微调（rank=32, lr=1e-5）。风格一致性评分 2.1 → 4.3（5 分制）。
- SFT 克隆优秀话务员安抚策略，RAG 负责时效性知识秒级更新，根治政策幻觉。构建 Embedding → 向量检索 → Cross-Encoder 精排三阶段 Pipeline，命中率 72% → 89%。
- 自动化指标（BLEU/ROUGE）快速排除失败 → 人工 A/B 盲评（50 用例 × 3 评估员，Cohen's Kappa 校准）核心指标 → 线上 A/B 验证。客户有效回复率提升 23%，会话时长提升 35%。

第三阶段：集团 AI 算力网关与多智能体共享基座（MCP 协议 / 多租户架构）（2025.06 ~ 至今）

- 基于 MCP 协议将算力路由、RAG 检索、会话记忆、Prompt 模板解耦为 4 个独立 MCP Server，通过标准化原语暴露，新业务接入周期由周级缩短 60% 至天级。
- 封装 OpenAI 格式标准 API，实现复杂任务→旗舰模型、简单查单→轻量模型的动态路由，YAML 热切换底层算力池，推理成本降低 40%。
- 基于火山引擎 Viking DB 按 project_id 物理隔离，Markdown 标题层级语义切分避免跨主题截断，召回率稳居 89%+。
- 单次对话按项目级隔离 + 大客户画像（发件偏好/时效要求/历史客诉）基于 PostgreSQL UPSERT 跨项目幂等更新，打通客服与理赔认知同步，消除数据孤岛。
- 全面 Stateless 化，核心状态下沉至共享 MCP 服务，业务微服务独立 Docker 镜像部署至 Serverless 集群，弹性伸缩支撑双十一流量洪峰，SIGTERM 优雅终止确保在途单据零丢失。

全球供应链合规与自动化单证中台（基于 LangGraph 架构）

AI 技术负责人 · 2025.06 ~ 至今

跨境物流场景海外单据格式杂乱（纸质面单、Excel 温控记录、PDF 发票混用），涉及中国海关、美国 FDA、欧盟 CE 等多套规则，人工审查周期 3-5 天/单，错漏率 12%。主导基于 LangGraph 图编排的自动化审查系统，覆盖单据解析、规则匹配、风险预警、单证生成全链路。

- 将单据解析、多源比对、规则审查拆分为独立编排单元，利用 PostgreSQL Checkpointer 实现全状态持久化与跨境规则版本隔离。通过 Thread-ID 路由实现单套规则更新时仅定向回滚对应子图，不破坏全局状态拓扑。
- 自研面向下游算力池的并发 QPS 流控，asyncio.gather + run_in_executor 将多模态解析及图像转换封装为协程开发，引入指数退避重试（1s→2s→4s）应对 LLM 抖动，吞吐量提升 3 倍。
- SSE 输出与 LangGraph astream_events 深度集成，监听 on_chat_model_stream 实时捕获 Token 级审计中间态，配合前端 ReadableStream 实现"进度可见 + 异步持久化"双轨制，TTFT 从 8s → 3s 内。
- 针对 HS 编码、原产地、净重等海关强校验字段，with_structured_output + Pydantic Schema 强约束报关 JSON。采用 JSON Mode 配合 TikToken 本地分词器流式累加补偿，攻克流式尾包 usage 缺失的开源顽疾。动态路由由简单任务→轻量模型 / 复杂任务→旗舰模型，通过率 95% 前提下推理成本降低 40%。
- 自研 MetricsContext 上下文管理器精准采集各图节点 Token 消耗与延迟，接入 LangSmith 实现 Graph 级全链路可观测；structlog 结构化日志 + 全局 Traceld 关联，故障定位从小时级 → 分钟级。
- 环境变量驱动 Mock 开关（llm_mock / image_mock / checkpointer_mock）切断外部依赖；Swagger UI 可视化评测 + Ngrok 公网映射，联调效率提升 3 倍，交付周期 2 天 → 半天，团队进化至日级发版。SlowAPI 接口限流 + 熔断器保护下游算力，Docker 容器化 + 优雅关闭确保零中断。

基于 Agent Harness 的 SWE-Agent 研发流程框架与效能底座

AI 技术负责人 · 2026.01 ~ 至今

针对大模型辅助编程（Vibe Coding）中极易陷入的零散对话式无序摸索、缺乏架构纪律与质量失控等痛点，主导研发 Agent Harness——一套高度泛化的大模型通用开发流程框架，将碎片化 AI 编程重构为标准工程闭环。

- 构建高隔离度的 Multi-Agent 协同与调度架构。设计主从调度模型，抽象出 implementer、code-reviewer、feedback-observer 等专职 Sub-Agent。确立沙盒级的强隔离原则，强制每个 Task 必须采用由 Controller 注入完整上下文的全新实例执行，彻底阻断长会话场景下的上下文污染与错误假设传递。
- 研发基于多维数据扫描的四层自动进化引擎。首创 Evolution Engine，通过后台子智能体静默扫描用户的修正信号与操作频次（occurrences），驱动"经验积累-规则毕业-Skill 优化-Skill 自动生成"的四层进化。当缺失规则的操作模式重复达到阈值时，系统自主调用 skill-builder 构建新模块，实现 Agent 工作流的闭环自生长。
- 基于 DAG 拓扑排序的端到端 SDLC 状态机编排。将软件开发生命周期重构为状态驱动的自动化流水线，系统通过自主检测 Product-Spec.md 和代码产物特征，精准路由由当前项目阶段。在开发规划期，利用有向无环图（DAG）构建功能依赖，运用"洋葱剥皮法"与"风险前置法"自动拆分高内聚的开发 Phase 与文件级交付清单。
- 设计三层模块化的高可扩展 Skill 插件网络。采用"原子能力-Skill-工作流"三层架构，以标准化的 Markdown 骨架实现高内聚、低耦合的技能封装。内置需求构建、开发规划等 11 项核心技能，并实现智能依赖检测与降级流转（Fallback）机制，支持如同堆积木般快速拓展全新的业务域能力。
- 落地强约束防幻觉工程纪律与自动化 QA 门禁。在编码流中强制推行"Code Review → 测试完整性 → 编译验证 → 功能测试"的四步走门禁，要求智能体的任何完成声明必须同源附带底层编译输出（如 tsc --noEmit）作为刚性证据，彻底杜绝大模型"幻觉式交付"。内置基于 AST/Grep 的隐私审计与 Spec 漂移检测，严防密钥硬编码与需求范围蔓延。
- 开发基于 JSON 配置的底层生命周期 Hook 拦截器。结合 CLI 运行环境，设计事件驱动的钩子系统，深度拦截 PreToolUse、PostToolUse 等关键执行树。例如通过 detect-feedback-signal.sh 实时正则监听用户的修正情绪并静默派发记录任务，以及通过 pre-commit-check.sh 自动化阻断未通过编译的 Git 提交，大幅增强系统自治能力。
- 整合 MCP 协议的高保真 Design-to-Code 还原引擎。创新性地设计工具（Figma/Pencil）通过 MCP 协议无缝接入开发链路，强制执行"组件先行"与"状态完备"原则。在编码阶段，系统实时调用 API 提取页面的精确设计数值（间距、字重、色彩等），并与生成的 Tailwind 样式进行双向交叉比对，消除了纯自然语言理解带来的视觉还原损耗。